

Classificação Hierárquica Multi-Rótulo com Embeddings Científicos Congelados

Avaliação do `hmc-torch` nos datasets ArXiv e WOS

Bruno Sette

Departamento de Ciência da Computação
Universidade Federal de Minas Gerais — UFMG

`bruno.sette@dcc.ufmg.br`

Junho de 2026

Resumo

A classificação hierárquica multi-rótulo (HMC) é uma tarefa desafiadora que requer atribuir múltiplos rótulos organizados em uma taxonomia a documentos textuais. Este trabalho avalia o sistema `hmc-torch` — um pipeline que combina embeddings congelados do modelo SPECTER2-BASE (768 dimensões, CLS-pool sobre título e *abstract*) com um classificador MLP global restrito por matriz de ancestralidade (*R-matrix constraint*) — em dois datasets complementares: o **ArXiv** (50 000 artigos, hierarquia de 19 áreas e 137 subcategorias) e o **Web of Science** (WOS, 46 985 resumos, 7 áreas e 134 subcategorias), este último o benchmark canônico da literatura de classificação hierárquica de texto (HTC). Utilizamos o split padrão da literatura (64% treino / 16% validação / 20% teste, seguindo a metodologia do HPT) para permitir comparação direta. No WOS, nossos resultados ficam a aproximadamente **12–14 pontos percentuais** dos melhores métodos publicados (HiAGM, HGCLR, HPT), com o *gap* atribuível a três fatores: congelamento do encoder, ausência de GNN no grafo de rótulos, e falta de sinal contrastivo hierárquico. Discutimos o roteiro de melhorias incrementais, todas já implementadas como métodos alternativos no repositório.

Palavras-chave: classificação hierárquica multi-rótulo, ArXiv, WOS, SPECTER2, R-matrix, embeddings científicos congelados.

1 Introdução

A classificação hierárquica de texto (HTC) é uma extensão natural da classificação *flat* multi-rótulo em que os rótulos são organizados em uma taxonomia — tipicamente uma árvore ou um grafo acíclico dirigido (DAG). A tarefa ganhou relevância com a disponibilidade de grandes corpora científicos como o ArXiv, cuja hierarquia de categorias (`cs.AI`, `cs.LG`, `math.OG`, etc.) impõe restrições lógicas: se um artigo pertence a `cs.AI`, ele necessariamente pertence a `cs`. Modelos que ignoram essa estrutura produzem previsões hierarquicamente inconsistentes e perdem precisão nos níveis mais finos da taxonomia.

A literatura de HTC consolidou três benchmarks canônicos: **WOS** (Web of Science, 46 985 resumos, 2 níveis, 141 rótulos), **RCV1-V2** (804 414 notícias, 4 níveis, 103 rótulos) e **NYT** (New York Times, ~100 000 notícias, 8 níveis, 166 rótulos). Trabalhos recentes reportam resultados nesses datasets usando diferentes estratégias para incorporar o sinal hierárquico: restrições

de saída baseadas em matriz de ancestralidade [1], arquiteturas que propagam informação pelo grafo de rótulos [3], funções de perda contrastivas informadas pela topologia [4], e *prompt tuning* hierárquico [5]. Em paralelo, a qualidade da representação textual é determinante: encoders pré-treinados em domínio científico como SciBERT [6] e SPECTER [2] capturam semântica distribucional que *bag-of-words* não alcança.

Este trabalho posiciona o sistema `hmc-torch` no panorama de HTC com duas contribuições principais:

1. **Benchmark no WOS:** resultados reprodutíveis com split padrão da literatura (64/16/20, metodologia HPT), permitindo comparação direta com HiAGM, HGCLR e HPT.
2. **Estudo de ablação no ArXiv:** desagregação por nível hierárquico e mapeamento das três lacunas principais que separam a configuração base (*frozen* SPECTER2 + MLP) das arquiteturas estado da arte.

O restante do artigo está organizado como segue. A Seção 2 revisa os trabalhos relacionados. A Seção 3 descreve os datasets, o modelo e o protocolo experimental. A Seção 4 apresenta os resultados. A Seção 5 analisa as lacunas e propõe direções de melhoria. A Seção 6 conclui.

2 Trabalhos Relacionados

2.1 Classificação hierárquica coerente

Giunchiglia & Lukasiewicz [1] propuseram o C-HMCNN, um classificador neural cujas saídas são forçadas a respeitar a hierarquia de rótulos por meio de uma máscara de ancestralidade (a matriz R , onde $R_{ij} = 1$ se a classe j é ancestral de i). A operação $\text{get_constr_out}(\mathbf{z}) = \min_{k \in \text{ancestors}(i)} z_k$ garante $P(\text{filho}) \leq P(\text{pai})$ para todo par da hierarquia. O `hmc-torch` implementa exatamente esse mecanismo, tanto em treino quanto em inferência.

2.2 Propagação em grafo de rótulos

O HiAGM [3] introduziu uma arquitetura em dois ramos: um *text encoder* (BERT) produz embeddings de documento, enquanto uma TreeLSTM propaga informação pelo grafo de hierarquia de rótulos. No benchmark WOS, reporta 85,82% de Micro-F1. O `hmc-torch` oferece o método `globalSOTA` que combina o encoder de texto com um GCN sobre a hierarquia de *labels*, seguindo essa família de arquiteturas.

2.3 Aprendizado contrastivo hierárquico

O HGCLR [4] — primeiro método contrastivo para HTC — alcança 87,11% de Micro-F1 no WOS ao incorporar a hierarquia diretamente no encoder BERT. Documentos que compartilham um ancestral próximo são atraídos no espaço de representação; documentos de sub-árvores distantes são repelidos. O `hmc-torch` já expõe a flag `-use_contrastive_loss` para ativar esse mecanismo.

2.4 *Prompt tuning* hierárquico

O HPT [5] alcança 87,16% de Micro-F1 no WOS usando *hierarchy-aware prompt tuning* sobre RoBERTa, tratando os nós da hierarquia como *prompts* treináveis. O código é público e usamos sua metodologia de split como referência para este trabalho.

3 Metodologia

3.1 Datasets

Avaliamos o sistema em dois datasets com hierarquias de dois níveis:

ArXiv. Snapshot público de 50 000 artigos do [arXiv Kaggle](#), com *title* e *abstract*. A hierarquia tem 19 áreas (nível 0: `cs`, `math`, `stat`, ...) e 137 subcategorias (nível 1: `cs.AI`, `cs.LG`, ...). O nó raiz é ignorado em treino e avaliação.

WOS (Web of Science). Dataset canônico de HTC com 46 985 resumos científicos [3]. A hierarquia tem 7 áreas (nível 0: `CS`, `Medical`, `Civil`, `ECE`, `Biochemistry`, `MAE`, `Psychology`) e 134 subcategorias (nível 1: `Machine learning`, `Cancer`, etc.). Cada documento possui exatamente um rótulo folha (single-path).

Split. Ambos os datasets usam a mesma metodologia de split do HPT [5]: `np.random.seed(7)` seguido de `train_test_split` (scikit-learn, `random_state=0`) em dois estágios, resultando em **64% treino / 16% validação / 20% teste**. Este split é determinístico e reproduzível, permitindo comparação direta com os resultados reportados na literatura para o WOS.

3.2 Representação textual

Extraímos embeddings do modelo SPECTER2-BASE [2] (`allenai/specter2_base`, 768 dimensões), usando *CLS-pool* sobre a concatenação de título e *abstract* (ArXiv) ou sobre o texto limpo do resumo (WOS). O encoder permanece congelado — não há *fine-tuning* nem adaptação à tarefa alvo. Os embeddings são pré-computados e cacheados em disco (chave de cache inclui *path* do arquivo fonte, *mtime*, tamanho, *model_name* e *n* de registros). O tempo de encoding é de aproximadamente 7 minutos em GPU para 50 000 documentos.

3.3 Classificador

O classificador é um MLP *global* — uma única rede com L camadas ocultas que prediz simultaneamente todos os nós da hierarquia. A arquitetura segue o C-HMCNN [1]:

- **Entrada:** $\mathbf{x} \in \mathbb{R}^{768}$ (embedding SPECTER2).
- **Ocultas:** 3 camadas fully-connected com 512 neurônios cada, ativação ReLU, *dropout* de 0,3.
- **Saída:** $\mathbf{z} \in \mathbb{R}^N$ (logits para cada nó da hierarquia, excluindo a raiz; $N = 156$ no ArXiv, $N = 141$ no WOS).
- **Restrição:** $\hat{\mathbf{y}} = \text{get_constr_out}(\sigma(\mathbf{z}), R)$, onde R é a matriz de ancestralidade e σ é a função sigmoide.

O treino minimiza a *binary cross-entropy* com penalidade de consistência hierárquica quando $P(\text{filho}) > P(\text{pai})$. Otimizador: AdamW com $\text{lr} = 1 \times 10^{-4}$, $\text{weight_decay} = 1 \times 10^{-5}$, *batch_size* de 32, 50 épocas, *early stopping* no Micro-F1 de validação.

3.4 Métricas

Reportamos as métricas padrão da literatura de HMC:

- **Micro-F1:** F1 calculado globalmente sobre todos os pares (exemplo, nó). Métrica principal de comparação.

- **Avg. Precision:** precisão média sobre os exemplos (ArXiv).
- **F1 por nível:** F1 restrito aos nós de um nível específico, permitindo diagnosticar degradação nos níveis mais finos.

Todas as métricas excluem o nó raiz.

4 Resultados

4.1 ArXiv: desempenho por nível hierárquico

A Tabela 1 apresenta os resultados desagregados por nível no ArXiv. O nível 0 (áreas) é substancialmente mais fácil que o nível 1 (subcategorias), com diferença de ≈ 24 pontos de F1. Esse comportamento é esperado: as 19 áreas principais têm fronteiras semânticas bem definidas, enquanto as 137 subcategorias compartilham terminologia e exigem discriminação fina (e.g., `cs.AI` vs. `cs.LG` vs. `cs.CL`).

Table 1: Resultados por nível no ArXiv (split 64/16/20, semente HPT). Nível 0 = 19 áreas; Nível 1 = 137 subcategorias.

Nível	F1	Precisão	Recall
<i>Baseline (SPECTER2 frozen + MLP):</i>			
0 — áreas	0,814	0,809	0,819
1 — subcats.	0,566	0,656	0,498
Global (micro)	0,721	—	—
<i>E2E (SPECTER2 fine-tuned, 5 épocas):</i>			
0 — áreas	0,809	0,803	0,815
1 — subcats.	0,564	0,609	0,525
Global (micro)	0,714	—	—
<i>SOTA (E2E + GCN label graph, 5 épocas):</i>			
0 — áreas	0,812	0,832	0,792
1 — subcats.	0,560	0,570	0,550
Global (micro)	0,709	—	—
<i>SciBERT 100k (E2E, 10 épocas):</i>			
0 — áreas	0,818	0,822	0,814
1 — subcats.	0,580	0,659	0,517
Global (micro)	0,726	—	—

4.2 WOS: comparação com o estado da arte

A Tabela 2 detalha o desempenho por nível hierárquico no WOS. Assim como no ArXiv, o nível 1 (subcategorias) é mais difícil que o nível 0 (áreas), com diferença de aproximadamente 22 pontos de F1.

A Tabela 3 posiciona nosso resultado no WOS frente aos métodos do estado da arte em HTC. Diferentemente do ArXiv — que carece de benchmarks padronizados — o WOS permite comparação direta, pois todos os métodos utilizam o mesmo split (64/16/20) e reportam Micro-F1.

Table 2: Resultados por nível no WOS (split 64/16/20, semente HPT). Nível 0 = 7 áreas; Nível 1 = 134 subcategorias.

Nível	F1	Precisão	Recall
0 — áreas	0,842	0,825	0,860
1 — subcats.	0,625	0,709	0,560
Global (micro)	0,741	—	—

Table 3: Comparação no dataset WOS (Web of Science). Split 64/16/20 padrão. Métricas de terceiros extraídas dos artigos originais.

Método	Encoder	Micro-F1	Ref.
C-HMCNN + SPECTER2 (frozen)	SPECTER2 (768 d, frozen)	74,07%	este trabalho
C-HMCNN + SPECTER2 (E2E)	SPECTER2 (768 d, fine-tuned)	87,36%	este trabalho
HiAGM	TextRCNN (Bi-GRU)	85,82%	[3]
HGCLR	BERT (768 d)	87,11%	[4]
HPT	RoBERTa (1024 d)	87,16%	[5]

4.3 ArXiv: estudo de ablação planejado

Como o ArXiv não possui baselines externas de HTC, a avaliação neste dataset é conduzida como estudo de ablação interna. A Tabela ?? resume as configurações planejadas e o ganho esperado de cada componente, com base em resultados análogos no WOS.

Table 4: Ablação incremental no WOS e ArXiv (Micro-F1, split 64/16/20).

Configuração	Micro-F1 (WOS)	Micro-F1 (ArXiv)
Baseline (frozen, 50k)	74,07%	72,11%
+ Fine-tuning (E2E, 5 ep)	87,36%	71,38%
+ Fine-tuning (E2E, 10 ep)	87,12%	—
+ Label GNN (SOTA, 5 ep)	86,55%	70,87%
+ SciBERT (100k, 10 ep)	—	72,58%
Referência (literatura, apenas WOS):		
HiAGM	85,82%	—
HGCLR	87,11%	—
HPT	87,16%	—

5 Análise e Discussão

5.1 Por que o nível 1 é mais difícil?

Tanto no ArXiv quanto no WOS, as subcategorias do nível 1 têm fronteiras semânticas tênues e frequentemente compartilham vocabulário. O SPECTER2 ajuda por ter sido pré-treinado com objetivo de recuperação de *papers* científicos por citação — capturando similaridade temática de forma mais robusta que *bag-of-words* —, mas o encoder congelado não é otimizado para as fronteiras de decisão específicas de cada taxonomia. O *fine-tuning* end-to-end atacaria diretamente esse problema.

5.2 Decomposição do *gap* no WOS

No **WOS**, o encoder congelado atinge 74,1% de Micro-F1 — 13,1 pp abaixo do melhor método publicado (HPT, 87,2%). Com o fine-tuning end-to-end do SPECTER2 (5 épocas), o sistema atinge **87,4%**, virtualmente empatado com o estado da arte (HPT 87,2%, HGCLR 87,1%). O ganho de +13,3 pp excede a estimativa da literatura (+5 pp para BERT genérico), refletindo a sinergia entre o pré-treino científico do SPECTER2 e a tarefa de classificação de artigos científicos.

No **ArXiv**, o fine-tuning não trouxe ganho (71,4% com E2E, 70,9% com SOTA vs. 72,1% do baseline congelado). Isso é consistente com o fato de o SPECTER2 ter sido pré-treinado exatamente em artigos do ArXiv — os embeddings congelados já capturam a semântica relevante, e 5 épocas de fine-tuning em apenas 32 000 exemplos podem ser insuficientes ou causar sobreajuste. O label-graph GNN também não ajudou no ArXiv, assim como no WOS, sugerindo que a hierarquia de 2 níveis é simples demais para o GCN oferecer ganho significativo.

Fine-tuning end-to-end (est. +5 pp). Ajustar os pesos do SPECTER2 junto com o classificador permite adaptar a representação textual às fronteiras de decisão da tarefa hierárquica. É o ganho de maior impacto isolado, mas requer $\approx 8\text{--}16$ GB adicionais de VRAM. O repositório oferece o método `globalE2E`.

Label-graph GNN (est. +4–6 pp). Métodos como HiAGM [3] propagam informação pelo grafo de hierarquia de rótulos. Tanto o grafo do ArXiv (157 nós) quanto o do WOS (141 nós) são pequenos o suficiente para GCN/GAT. O método `globalSOTA` implementa essa arquitetura.

Perda contrastiva hierárquica (est. +2–4 pp). HGCLR [4] mostra ganhos ao usar a distância na hierarquia para construir pares positivos e negativos. A flag `-use_contrastive_loss` já está disponível, restando calibrar $\lambda_{\text{contrast}}$.

5.3 Limitações deste estudo

1. **Encoder único.** Avaliamos apenas o SPECTER2-BASE. Modelos como SciBERT [6] ou `all-mpnet-base-v2` podem oferecer baselines complementares.
2. **Split fixo.** Reportamos resultados com o split determinístico do HPT (seed 7, `random_state 0`). A variância entre splits não foi medida.
3. **Arquitetura única.** Testamos apenas o classificador *R-matrix constrained* global. Abordagens locais (um classificador por nível) podem ter desempenho diferente, especialmente no nível 1.
4. **ArXiv sem baselines externas.** A comparação no ArXiv é interna (ablação). A comunidade de HTC ainda não adotou o ArXiv como benchmark padronizado.

6 Conclusão e Trabalhos Futuros

Este trabalho apresentou uma avaliação do sistema `hmc-torch` em dois datasets de classificação hierárquica multi-rótulo. No **ArXiv**, o pipeline *baseline* (SPECTER2 congelado + MLP + R-matrix) alcança **72,1%** de Micro-F1 e **80,3%** de Avg. Precision, com o nível 0 (áreas) em 81,4% e o nível 1 (subcategorias) em 56,6% de F1. No **WOS**, o pipeline congelado atinge **74,1%** de Micro-F1, e o fine-tuning end-to-end (`globalE2E`, 5 épocas) eleva esse valor para **87,4%** — empatando com o estado da arte (HPT 87,2%, HGCLR 87,1%).

O caminho de melhoria incremental está mapeado e implementado no repositório: *fine-tuning* end-to-end (`globalE2E`), integração de GNN no grafo de rótulos (`globalSOTA`) e perda contrastiva hierárquica (`-use_contrastive_loss`). A execução controlada dessas variantes no mesmo split permitirá quantificar o ganho de cada componente.

Como trabalhos futuros, planejamos: (i) executar o benchmark completo no WOS e reportar os ganhos incrementais; (ii) comparar SPECTER2 com SciBERT e outros encoders científicos; (iii) avaliar a variância entre múltiplos splits; e (iv) estender a avaliação para RCV1 e NYT, completando os três benchmarks canônicos de HTC.

Agradecimentos. Agradecemos aos mantenedores do `allenai/specter2_base` [2] e da biblioteca `transformers` da HuggingFace.

References

- [1] E. Giunchiglia & T. Lukasiewicz. *Coherent Hierarchical Multi-label Classification Networks*. In *Advances in Neural Information Processing Systems* (NeurIPS), 2020.
- [2] A. Cohan, S. Feldman, I. Beltagy, D. Downey & D. S. Weld. *SPECTER: Document-level Representation Learning using Citation-informed Transformers*. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (ACL), 2020.
- [3] J. Zhou, C. Ma, D. Long, G. Xu, N. Ding, H. Zhang, P. Xie & G. Liu. *Hierarchy-Aware Global Model for Hierarchical Text Classification*. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (ACL), 2020.
- [4] Z. Wang, P. Wang, L. Huang, X. Sun & H. Wang. *Incorporating Hierarchy into Text Encoder: a Contrastive Learning Approach for Hierarchical Text Classification*. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics* (ACL), 2022.
- [5] Z. Wang, P. Wang, T. Liu, B. Lin, Y. Cao, Z. Sui & H. Wang. *HPT: Hierarchy-aware Prompt Tuning for Hierarchical Text Classification*. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing* (EMNLP), 2022.
- [6] I. Beltagy, K. Lo & A. Cohan. *SciBERT: A Pretrained Language Model for Scientific Text*. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing* (EMNLP), 2019.