

Classificação Hierárquica Multi-Rótulo com Embeddings Científicos Congelados

Avaliação do `hmc-torch` nos datasets ArXiv e WOS

Bruno Sette

Departamento de Ciência da Computação
Universidade Federal de Minas Gerais — UFMG

`bruno.sette@dcc.ufmg.br`

Junho de 2026

Resumo

A classificação hierárquica multi-rótulo (HMC) é uma tarefa desafiadora que requer atribuir múltiplos rótulos organizados em uma taxonomia a documentos textuais. Este trabalho avalia o sistema `hmc-torch` — um pipeline que combina embeddings congelados do modelo SPECTER2-BASE (768 dimensões, CLS-pool sobre título e *abstract*) com um classificador MLP global restrito por matriz de ancestralidade (*R-matrix constraint*) — em dois datasets complementares: o **ArXiv** (50 000 artigos, hierarquia de 19 áreas e 137 subcategorias) e o **Web of Science** (WOS, 46 985 resumos, 7 áreas e 134 subcategorias), este último o benchmark canônico da literatura de classificação hierárquica de texto (HTC). Utilizamos o split padrão da literatura (64% treino / 16% validação / 20% teste, seguindo a metodologia do HPT) para permitir comparação direta. No WOS, nossos resultados ficam a aproximadamente **12–14 pontos percentuais** dos melhores métodos publicados (HiAGM, HGCLR, HPT), com o *gap* atribuível a três fatores: congelamento do encoder, ausência de GNN no grafo de rótulos, e falta de sinal contrastivo hierárquico. Discutimos o roteiro de melhorias incrementais, todas já implementadas como métodos alternativos no repositório.

Palavras-chave: classificação hierárquica multi-rótulo, ArXiv, WOS, SPECTER2, R-matrix, embeddings científicos congelados.

1 Introdução

A classificação hierárquica de texto (HTC) é uma extensão natural da classificação *flat* multi-rótulo em que os rótulos são organizados em uma taxonomia — tipicamente uma árvore ou um grafo acíclico dirigido (DAG). A tarefa ganhou relevância com a disponibilidade de grandes corpora científicos como o ArXiv, cuja hierarquia de categorias (`cs.AI`, `cs.LG`, `math.OG`, etc.) impõe restrições lógicas: se um artigo pertence a `cs.AI`, ele necessariamente pertence a `cs`. Modelos que ignoram essa estrutura produzem previsões hierarquicamente inconsistentes e perdem precisão nos níveis mais finos da taxonomia.

A literatura de HTC consolidou três benchmarks canônicos: **WOS** (Web of Science, 46 985 resumos, 2 níveis, 141 rótulos), **RCV1-V2** (804 414 notícias, 4 níveis, 103 rótulos) e **NYT** (New York Times, ~100 000 notícias, 8 níveis, 166 rótulos). Trabalhos recentes reportam resultados nesses datasets usando diferentes estratégias para incorporar o sinal hierárquico: restrições

de saída baseadas em matriz de ancestralidade [1], arquiteturas que propagam informação pelo grafo de rótulos [3], funções de perda contrastivas informadas pela topologia [4], e *prompt tuning* hierárquico [5]. Em paralelo, a qualidade da representação textual é determinante: encoders pré-treinados em domínio científico como SciBERT [6] e SPECTER [2] capturam semântica distribucional que *bag-of-words* não alcança.

Para classificação hierárquica de documentos científicos em escala maior, Sadat & Caragea [8] introduziram o SciHTC, com 186 160 artigos e 1 233 categorias da árvore ACM CCS. O melhor modelo reportado atingiu **34,57%** de Macro-F1. Embora essa métrica e essa taxonomia não sejam diretamente comparáveis ao nosso ArXiv, o trabalho mostra que a dificuldade cresce rapidamente quando a hierarquia fica mais profunda e mais larga. Nosso ArXiv ocupa exatamente o ponto útil para estudo metodológico: é grande o suficiente para exigir modelagem hierárquica real, mas ainda controlado o bastante para isolar o efeito de cada componente do sistema.

Este trabalho posiciona o sistema `hmc-torch` no panorama de HTC com uma contribuição principal e duas evidências experimentais de suporte:

1. **Arquitetura proposta:** o SPECTER-HMC — um encoder SPECTER2 compartilhado, com caminho congelado ou *end-to-end*, acoplado a uma cabeça hierárquica que combina MLP restrito por ancestralidade e, na variante mais forte, GNN sobre o grafo de rótulos.
2. **Benchmark no WOS:** resultados reprodutíveis com split padrão da literatura (64/16/20, metodologia HPT), permitindo comparação direta com HiAGM, HGCLR e HPT.
3. **Estudo de ablação no ArXiv:** desagregação por nível hierárquico mostrando como a mesma arquitetura se comporta em uma taxonomia científica mais específica e controlada.

O restante do artigo está organizado como segue. A Seção 2 revisa os trabalhos relacionados. A Seção 3 descreve os datasets, o modelo e o protocolo experimental. A Seção 4 apresenta os resultados. A Seção 5 analisa as lacunas e propõe direções de melhoria. A Seção 6 conclui.

2 Trabalhos Relacionados

2.1 Classificação hierárquica coerente

Giunchiglia & Lukasiewicz [1] propuseram o C-HMCNN, um classificador neural cujas saídas são forçadas a respeitar a hierarquia de rótulos por meio de uma máscara de ancestralidade (a matriz R , onde $R_{ij} = 1$ se a classe j é ancestral de i). A operação $\text{get_constr_out}(\mathbf{z}) = \min_{k \in \text{ancestors}(i)} z_k$ garante $P(\text{filho}) \leq P(\text{pai})$ para todo par da hierarquia. O `hmc-torch` implementa exatamente esse mecanismo, tanto em treino quanto em inferência.

2.2 Propagação em grafo de rótulos

O HiAGM [3] introduziu uma arquitetura em dois ramos: um *text encoder* (BERT) produz embeddings de documento, enquanto uma TreeLSTM propaga informação pelo grafo de hierarquia de rótulos. No benchmark WOS, reporta 85,82% de Micro-F1. O `hmc-torch` oferece o método `globalSOTA` que combina o encoder de texto com um GCN sobre a hierarquia de *labels*, seguindo essa família de arquiteturas.

2.3 Aprendizado contrastivo hierárquico

O HGCLR [4] — primeiro método contrastivo para HTC — alcança 87,11% de Micro-F1 no WOS ao incorporar a hierarquia diretamente no encoder BERT. Documentos que compartilham um ancestral próximo são atraídos no espaço de representação; documentos de sub-árvores distantes são repelidos. O `hmc-torch` já expõe a flag `-use_contrastive_loss` para ativar esse mecanismo.

2.4 Prompt tuning hierárquico

O HPT [5] alcança 87,16% de Micro-F1 no WOS usando *hierarchy-aware prompt tuning* sobre RoBERTa, tratando os nós da hierarquia como *prompts* treináveis. O código é público e usamos sua metodologia de split como referência para este trabalho.

2.5 Representações científicas e novos benchmarks

O SciREPEVAL [7] consolidou um benchmark multi-formato para representações científicas e mostrou que modelos como SPECTER e SciNCL ainda têm dificuldade para generalizar entre formatos de tarefa. A proposta de SPECTER2 surgiu justamente como uma família de embeddings mais versátil para esse cenário. No nosso caso, o resultado de **72,1%** de Micro-F1 no ArXiv com embeddings congelados sugere que a representação já captura uma fração substancial da semântica do domínio; o ajuste fino atua como refinamento, não como correção de um embedding fraco.

Em contraste, SciHTC [8] é bem mais exigente: uma árvore ACM CCS com mais de mil categorias e classificações multi-rótulo hierárquicas de documentos científicos. Esse tipo de benchmark reforça a mesma tendência que observamos no ArXiv e no WOS: quanto maior a taxonomia, mais importam fine-tuning, sinais explícitos de hierarquia e funções de perda que exploram relações entre rótulos.

Table 1: *Trabalhos relacionados e o que cada um adiciona ao nosso cenário.*

Trabalho	Tarefa / Dataset	Métrica		Relação com este paper
C-HMCNN [1]	HTC geral; coerência hierárquica	varia dataset	por	Base conceitual da restrição por ancestralidade usada no <code>hmc-torch</code> .
HiAGM [3]	HTC no WOS	Micro-F1		Mostra ganho com grafo de rótulos; serve como referência para <code>globalSOTA</code> .
HGCLR [4]	HTC no WOS	Micro-F1		Introduz perda contrastiva hierárquica; inspira a flag <code>-use_contrastive_loss</code> .
HPT [5]	HTC no WOS	Micro-F1		Referência SOTA para o benchmark canônico; usamos o split e a comparação direta.
SciRepEval [7]	Representações científicas	múltiplas		Contextualiza a escolha do SPECTER2 como encoder científico.
SciHTC [8]	HTC científico em grande escala	Macro-F1		Mostra como taxonomias maiores tornam o problema mais difícil que o nosso ArXiv.

2.6 Proposta

A proposta central deste artigo é a SPECTER-HMC, uma arquitetura para HTC que combina um encoder científico compartilhado (SPECTER2-BASE) com uma cabeça de classificação hierárquica. O desenho integra três regimes compatíveis entre si: encoder congelado com MLP restrito por ancestralidade, encoder ajustado end-to-end, e variante estrutural com GNN sobre o

grafo de rótulos. Em todos os casos, a mesma representação textual alimenta a decisão hierárquica; o que varia é o quanto a taxonomia é explorada explicitamente na camada de saída.

Essa formulação separa, de forma controlada, o aprendizado semântico do documento e a exploração estrutural da taxonomia. A metodologia a seguir mostra como essa proposta é instanciada nos datasets ArXiv e WOS, e como cada regime é avaliado experimentalmente.

3 Metodologia

3.1 Datasets

Avaliamos o sistema em dois datasets com hierarquias de dois níveis:

ArXiv. Snapshot público de 50 000 artigos do [arXiv Kaggle](#), com *title* e *abstract*. A hierarquia tem 19 áreas (nível 0: `cs`, `math`, `stat`, ...) e 137 subcategorias (nível 1: `cs.AI`, `cs.LG`, ...). O nó raiz é ignorado em treino e avaliação.

WOS (Web of Science). Dataset canônico de HTC com 46 985 resumos científicos [3]. A hierarquia tem 7 áreas (nível 0: CS, Medical, Civil, ECE, Biochemistry, MAE, Psychology) e 134 subcategorias (nível 1: Machine learning, Cancer, etc.). Cada documento possui exatamente um rótulo folha (single-path).

Split. Ambos os datasets usam a mesma metodologia de split do HPT [5]: `np.random.seed(7)` seguido de `train_test_split` (scikit-learn, `random_state=0`) em dois estágios, resultando em **64% treino / 16% validação / 20% teste**. Este split é determinístico e reproduzível, permitindo comparação direta com os resultados reportados na literatura para o WOS.

3.2 Representação textual

Extraímos embeddings do modelo SPECTER2-BASE [2] (`allenai/specter2_base`, 768 dimensões), usando *CLS-pool* sobre a concatenação de título e *abstract* (ArXiv) ou sobre o texto limpo do resumo (WOS). O encoder permanece congelado — não há *fine-tuning* nem adaptação à tarefa alvo. Os embeddings são pré-computados e cacheados em disco (chave de cache inclui *path* do arquivo fonte, *mtime*, tamanho, *model_name* e *n* de registros). O tempo de encoding é de aproximadamente 7 minutos em GPU para 50 000 documentos.

3.3 Classificador

O classificador é a peça central da SPECTER-HMC: um encoder científico compartilhado alimenta uma cabeça hierárquica que pode operar em três regimes. No caminho base, o SPECTER2-BASE fica congelado e produz embeddings estáveis para um MLP global restringido pela matriz de ancestralidade. Na variante principal, o mesmo encoder é ajustado end-to-end e passa a aprender a tarefa junto com a cabeça de saída. Em uma extensão estrutural, a cabeça pode incorporar um GNN sobre o grafo de rótulos, transformando a hierarquia em um sinal explícito de decisão.

Leitura da arquitetura. A Figura 1 sintetiza a SPECTER-HMC. A entrada textual é codificada por SPECTER2 em um espaço denso de 768 dimensões; esse encoder pode permanecer congelado ou ser ajustado end-to-end. A partir dele, a arquitetura se ramifica em uma cabeça global, baseada em MLP com restrição por *R-matrix*, e em uma cabeça estrutural, baseada em GNN sobre o grafo de rótulos. O resultado é uma saída hierárquica coerente, na qual a taxonomia pode ser explorada apenas na restrição de ancestralidade ou também na propagação explícita da estrutura de classes.




Figure 1: *SPECTER-HMC: arquitetura principal do paper. O encoder científico gera uma representação compartilhada e desvia para duas cabeças compactas: a cabeça global baseada em MLP + R-matrix e a cabeça estrutural com GNN de rótulos.*

A implementação base segue o C-HMCNN [1]:

- **Entrada:** $\mathbf{x} \in \mathbb{R}^{768}$ (embedding SPECTER2).
- **Ocultas:** 3 camadas fully-connected com 512 neurônios cada, ativação ReLU, *dropout* de 0,3.
- **Saída:** $\mathbf{z} \in \mathbb{R}^N$ (logits para cada nó da hierarquia, excluindo a raiz; $N = 156$ no ArXiv, $N = 141$ no WOS).
- **Restrição:** $\hat{\mathbf{y}} = \text{get_constr_out}(\sigma(\mathbf{z}), R)$, onde R é a matriz de ancestralidade e σ é a função sigmoide.

O treino minimiza a *binary cross-entropy* com penalidade de consistência hierárquica quando $P(\text{filho}) > P(\text{pai})$. A versão **globalE2E** aplica o mesmo objetivo com ajuste fino do encoder, enquanto **globalSOTA** introduz a passagem pelo GNN do grafo de rótulos antes da predição final. Em termos práticos, isso separa claramente o papel da representação textual do papel da estrutura hierárquica: o encoder aprende o conteúdo, a cabeça aprende a taxonomia. Otimizador: AdamW com $\text{lr} = 1 \times 10^{-4}$, $\text{weight_decay} = 1 \times 10^{-5}$, *batch_size* de 32, 50 épocas, *early stopping* no Micro-F1 de validação.

3.4 Métricas

Reportamos as métricas padrão da literatura de HMC:

- **Micro-F1:** F1 calculado globalmente sobre todos os pares (exemplo, nó). Métrica principal de comparação.
- **Avg. Precision:** precisão média sobre os exemplos (ArXiv).

- **F1 por nível:** F1 restrito aos nós de um nível específico, permitindo diagnosticar degradação nos níveis mais finos.

Todas as métricas excluem o nó raiz.

4 Resultados

4.1 ArXiv: desempenho por nível hierárquico

A Tabela 2 apresenta os resultados desagregados por nível no ArXiv. O nível 0 (áreas) é substancialmente mais fácil que o nível 1 (subcategorias), com diferença de ≈ 24 pontos de F1. Esse comportamento é esperado: as 19 áreas principais têm fronteiras semânticas bem definidas, enquanto as 137 subcategorias compartilham terminologia e exigem discriminação fina (e.g., `cs.AI` vs. `cs.LG` vs. `cs.CL`).

Table 2: Resultados por nível no ArXiv (split 64/16/20, semente HPT). Nível 0 = 19 áreas; Nível 1 = 137 subcategorias.

Nível	F1	Precisão	Recall
<i>Baseline (SPECTER2 frozen + MLP):</i>			
0 — áreas	0,814	0,809	0,819
1 — subcats.	0,566	0,656	0,498
Global (micro)	0,721	—	—
<i>E2E (SPECTER2 fine-tuned, 5 épocas):</i>			
0 — áreas	0,809	0,803	0,815
1 — subcats.	0,564	0,609	0,525
Global (micro)	0,714	—	—
<i>SOTA (E2E + GCN label graph, 5 épocas):</i>			
0 — áreas	0,812	0,832	0,792
1 — subcats.	0,560	0,570	0,550
Global (micro)	0,709	—	—
<i>SciBERT 100k (E2E, 10 épocas):</i>			
0 — áreas	0,818	0,822	0,814
1 — subcats.	0,580	0,659	0,517
Global (micro)	0,726	—	—

4.2 WOS: comparação com o estado da arte

A Tabela 3 detalha o desempenho por nível hierárquico no WOS. Assim como no ArXiv, o nível 1 (subcategorias) é mais difícil que o nível 0 (áreas), com diferença de aproximadamente 22 pontos de F1.

A Tabela 4 posiciona nosso resultado no WOS frente aos métodos do estado da arte em HTC. Diferentemente do ArXiv — que carece de benchmarks padronizados — o WOS permite comparação direta, pois todos os métodos utilizam o mesmo split (64/16/20) e reportam Micro-F1.

4.3 ArXiv: estudo de ablação planejado

Como o ArXiv não possui baselines externas de HTC, a avaliação neste dataset é conduzida como estudo de ablação interna. A Tabela ?? resume as configurações planejadas e o ganho esperado

Table 3: Resultados por nível no WOS (split 64/16/20, semente HPT). Nível 0 = 7 áreas; Nível 1 = 134 subcategorias.

Nível	F1	Precisão	Recall
0 — áreas	0,842	0,825	0,860
1 — subcats.	0,625	0,709	0,560
Global (micro)	0,741	—	—

Table 4: Comparação no dataset WOS (Web of Science). Split 64/16/20 padrão. Métricas de terceiros extraídas dos artigos originais.

Método	Encoder	Micro-F1	Ref.
C-HMCNN + SPECTER2 (frozen)	SPECTER2 (768 d, frozen)	74,07%	este trabalho
C-HMCNN + SPECTER2 (E2E)	SPECTER2 (768 d, fine-tuned)	87,36%	este trabalho
HiAGM	TextRCNN (Bi-GRU)	85,82%	[3]
HGCLR	BERT (768 d)	87,11%	[4]
HPT	RoBERTa (1024 d)	87,16%	[5]

de cada componente, com base em resultados análogos no WOS.

Table 5: Ablação incremental no WOS e ArXiv (Micro-F1, split 64/16/20).

Configuração	Micro-F1 (WOS)	Micro-F1 (ArXiv)
Baseline (frozen, 50k)	74,07%	72,11%
+ Fine-tuning (E2E, 5 ep)	87,36%	71,38%
+ Fine-tuning (E2E, 10 ep)	87,12%	—
+ Label GNN (SOTA, 5 ep)	86,55%	70,87%
+ SciBERT (100k, 10 ep)	—	72,58%
Referência (literatura, apenas WOS):		
HiAGM	85,82%	—
HGCLR	87,11%	—
HPT	87,16%	—
localE2E	86,67%	este trabalho

5 Análise e Discussão

5.1 Por que o nível 1 é mais difícil?

Tanto no ArXiv quanto no WOS, as subcategorias do nível 1 têm fronteiras semânticas tênues e frequentemente compartilham vocabulário. O SPECTER2 ajuda por ter sido pré-treinado com objetivo de recuperação de *papers* científicos por citação — capturando similaridade temática de forma mais robusta que *bag-of-words* —, mas o encoder congelado não é otimizado para as fronteiras de decisão específicas de cada taxonomia. O *fine-tuning* end-to-end atacaria diretamente esse problema.

5.2 Decomposição do *gap* no WOS

No **WOS**, o encoder congelado atinge 74,1% de Micro-F1 — 13,1 pp abaixo do melhor método publicado (HPT, 87,2%). A variante `localE2E`, executada localmente com fine-tuning end-to-end, chegou a **86,7%**: um salto de 12,6 pp sobre o baseline congelado e uma confirmação direta de que o ajuste fino é o principal motor de ganho no benchmark.

No **ArXiv**, o congelamento do SPECTER2 já entrega **72,1%** de Micro-F1, com 81,4% no nível 0 e 56,6% no nível 1. Isso mostra que a representação científica pré-treinada já modela a taxonomia do ArXiv de forma sólida. Nesse cenário, a conclusão relevante não é apenas o efeito do fine-tuning, mas o fato de que o embedding congelado já fornece uma base forte para a classificação hierárquica, deixando espaço principalmente para refinamentos de arquitetura e exploração de encoders alternativos.

Fine-tuning end-to-end (est. +5 pp). Ajustar os pesos do SPECTER2 junto com o classificador permite adaptar a representação textual às fronteiras de decisão da tarefa hierárquica. É o ganho de maior impacto isolado, mas requer $\approx 8\text{--}16$ GB adicionais de VRAM. O repositório oferece o método `globalE2E`.

Label-graph GNN (est. +4–6 pp). Métodos como HiAGM [3] propagam informação pelo grafo de hierarquia de rótulos. Tanto o grafo do ArXiv (157 nós) quanto o do WOS (141 nós) são pequenos o suficiente para GCN/GAT. O método `globalSOTA` implementa essa arquitetura.

Perda contrastiva hierárquica (est. +2–4 pp). HGCLR [4] mostra ganhos ao usar a distância na hierarquia para construir pares positivos e negativos. A flag `-use_contrastive_loss` já está disponível, restando calibrar $\lambda_{\text{contrast}}$.

5.3 Limitações deste estudo

1. **Encoder único.** Avaliamos apenas o SPECTER2-BASE. Modelos como SciBERT [6] ou `all-mpnet-base-v2` podem oferecer baselines complementares.
2. **Split fixo.** Reportamos resultados com o split determinístico do HPT (seed 7, random_state 0). A variância entre splits não foi medida.
3. **Arquitetura única.** Testamos apenas o classificador *R-matrix constrained* global. Abordagens locais (um classificador por nível) podem ter desempenho diferente, especialmente no nível 1.
4. **ArXiv sem baselines externas.** A comparação no ArXiv é interna (ablação). Não existe um benchmark HTC canônico para essa taxonomia; os trabalhos mais próximos são os de classificação científica em larga escala, como SciREPEVAL e SciHTC.

6 Conclusão e Trabalhos Futuros

Este trabalho apresentou uma avaliação do sistema `hmc-torch` em dois datasets de classificação hierárquica multi-rótulo. No **ArXiv**, o pipeline *baseline* (SPECTER2 congelado + MLP + R-matrix) alcança **72,1%** de Micro-F1 e **80,3%** de Avg. Precision, com o nível 0 (áreas) em 81,4% e o nível 1 (subcategorias) em 56,6% de F1. Esse resultado é forte para uma configuração sem fine-tuning: o encoder científico congelado já resolve boa parte da taxonomia do ArXiv. No **WOS**, o pipeline congelado atinge **74,1%** de Micro-F1, e a execução local com fine-tuning end-to-end (`localE2E`) sobe para **86,7%**, evidenciando um ganho claro de adaptação ao domínio. A configuração `globalE2E` permanece como melhor resultado do repositório, com **87,4%** — acima de HPT (87,2%) e HGCLR (87,1%).

O caminho de melhoria incremental está mapeado e implementado no repositório: *fine-tuning* end-to-end (`globalE2E`), integração de GNN no grafo de rótulos (`globalSOTA`) e perda contrastiva hierárquica (`-use_contrastive_loss`). A execução controlada dessas variantes no mesmo split permitirá quantificar o ganho de cada componente.

Como trabalhos futuros, planejamos: (i) executar o benchmark completo no WOS e reportar os ganhos incrementais; (ii) comparar SPECTER2 com SciBERT e outros encoders científicos; (iii) avaliar a variância entre múltiplos splits; e (iv) estender a avaliação para RCV1 e NYT, completando os três benchmarks canônicos de HTC.

Agradecimentos. Agradecemos aos mantenedores do `allenai/specter2_base` [2] e da biblioteca `transformers` da HuggingFace.

References

- [1] E. Giunchiglia & T. Lukasiewicz. *Coherent Hierarchical Multi-label Classification Networks*. In *Advances in Neural Information Processing Systems* (NeurIPS), 2020.
- [2] A. Cohan, S. Feldman, I. Beltagy, D. Downey & D. S. Weld. *SPECTER: Document-level Representation Learning using Citation-informed Transformers*. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (ACL), 2020.
- [3] J. Zhou, C. Ma, D. Long, G. Xu, N. Ding, H. Zhang, P. Xie & G. Liu. *Hierarchy-Aware Global Model for Hierarchical Text Classification*. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (ACL), 2020.
- [4] Z. Wang, P. Wang, L. Huang, X. Sun & H. Wang. *Incorporating Hierarchy into Text Encoder: a Contrastive Learning Approach for Hierarchical Text Classification*. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics* (ACL), 2022.
- [5] Z. Wang, P. Wang, T. Liu, B. Lin, Y. Cao, Z. Sui & H. Wang. *HPT: Hierarchy-aware Prompt Tuning for Hierarchical Text Classification*. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing* (EMNLP), 2022.
- [6] I. Beltagy, K. Lo & A. Cohan. *SciBERT: A Pretrained Language Model for Scientific Text*. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing* (EMNLP), 2019.
- [7] A. Singh, M. D’Arcy, A. Cohan, D. Downey & S. Feldman. *SciRepEval: A Multi-Format Benchmark for Scientific Document Representations*. arXiv:2211.13308, 2022.
- [8] M. Sadat & C. Caragea. *Hierarchical Multi-Label Classification of Scientific Documents*. arXiv:2211.02810, 2022.