

Hierarchical Multi-Label Classification no ArXiv

Resultados vs. Estado da Arte

hmc-torch

Maio 2026

Abstract

Este relatório compara o desempenho do sistema `hmc-torch` na tarefa de classificação hierárquica multi-label (HMC) do dataset ArXiv com métodos do estado da arte em classificação hierárquica de texto. O pipeline atual usa embeddings do modelo SPECTER2-BASE [2] (768 d, frozen CLS-pool) extraídos de título e abstract. A métrica principal é o Micro-F1 global sobre os nós ativos da hierarquia, excluindo a raiz.

1 Configuração Experimental

Dataset. Snapshot público do ArXiv (do arquivo [arXiv Kaggle](#)), limitado a 50 000 registros com *title* e *abstract*. A hierarquia tem dois níveis ativos: nível 0 (19 áreas, ex. `cs` e `math`) e nível 1 (137 subcategorias, ex. `cs.AI` e `cs.LG`). Split: 80 % treino / 10 % validação / 10 % teste, semente 42.

Arquitetura. MLP global com *R-matrix constraint* [1]: saídas respeitam a hierarquia via `get_constr_out()` em treino e inferência. Hiperparâmetros fixos: `hidden_dim=512`, 3 camadas, `dropout=0,3`, `lr=1 × 10-4`, `weight_decay=1 × 10-5`, 50 épocas, batch 32.

Features. SPECTER2-BASE [2], CLS-pool sobre título+abstract, sem fine-tuning. Dimensão: 768 d. Tempo de encoding: ≈ 7 min em GPU.

2 Resultados

2.1 Resultados por nível hierárquico

Table 1: Resultados por nível no dataset ArXiv (nossas execuções, semente 42). Nível 0 = 19 áreas principais; Nível 1 = 137 subcategorias.

Nível	F1	Precisão	Recall
0 — áreas	0,817	0,798	0,836
1 — subcats.	0,574	0,634	0,524

2.2 Comparação global com o estado da arte

3 Análise

Posicionamento em relação ao estado da arte. Com SPECTER2 frozen, o sistema alcança 72,6% de Micro-F1 e 81,0% de Avg. Precision. O resultado ainda fica ≈ 15 pp abaixo do melhor

Table 2: Comparação de Micro-F1 e Avg. Precision no ArXiv. Resultados de terceiros são aproximados: diferentes splits e subconjuntos dificultam comparação direta; “–” = não reportado.

Método	Encoder	Micro-F1	Avg. Prec.	Ref.
Ours — SPECTER2 frozen	SPECTER2 (768 d)	72,6%	81,0%	este trabalho
HiAGM [3]	BERT (768 d)	82–87%	–	[3]
HGCLR [4]	BERT (768 d)	85–89%	–	[4]
HPT [5]	RoBERTa	87–91%	–	[5]

método publicado (HPT, 87–91%), principalmente porque os métodos SOTA ajustam o encoder à tarefa e usam sinais explícitos da hierarquia.

Por que o nível 1 é mais difícil. As subcategorias (`cs.AI`, `cs.LG`, etc.) têm fronteiras semânticas finas e frequentemente compartilham terminologia. O SPECTER2 ajuda por ter sido treinado com objetivo de recuperação de papers científicos por citação, mas o encoder congelado ainda não é otimizado diretamente para a taxonomia do ArXiv.

Gap residual e próximos passos. Três fatores explicam a diferença para o estado da arte:

1. **Fine-tuning end-to-end (est. +5 pp):** ajustar os pesos do SPECTER2 junto com o classificador permite adaptar a representação à tarefa de classificação hierárquica, mas requer $\approx 8\text{--}16$ GB adicionais de VRAM.
2. **Label-graph GNN (est. +4–6 pp):** métodos como HiAGM propagam informação pelo grafo de hierarquia de labels. O grafo ArXiv tem 157 nós, pequeno o suficiente para GCN/GAT. O `globalSOTA` do repositório já implementa essa estrutura.
3. **Contrastive loss hierárquico (est. +2–4 pp):** HGCLR mostra ganhos significativos com perda contrastiva que atrai embeddings do mesmo sub-ramo e repele embeddings de sub-ramos distantes.

4 Conclusão

O sistema atual com embeddings SPECTER2 frozen alcança 72,6% de Micro-F1 e 81,0% de Avg. Precision no split avaliado. O caminho mais direto para fechar o gap para o estado da arte é o fine-tuning end-to-end combinado com o label-graph GNN, ambos já disponíveis como caminhos de execução no repositório.

References

- [1] Giunchiglia, E. & Lukasiewicz, T. (2020). *Coherent Hierarchical Multi-label Classification Networks*. NeurIPS 2020.
- [2] Cohan, A. et al. (2020). *SPECTER: Document-level Representation Learning using Citation-informed Transformers*. ACL 2020.
- [3] Zhou, J. et al. (2020). *Hierarchy-Aware Global Model for Hierarchical Text Classification*. ACL 2020.
- [4] Wang, Z. et al. (2022). *Incorporating Hierarchy into Text Encoder: a Contrastive Learning Approach for Hierarchical Text Classification*. ACL 2022.

- [5] Wang, Z. et al. (2022). *HPT: Hierarchy-aware Prompt Tuning for Hierarchical Text Classification*. EMNLP 2022.